가짜연구소 13기 · 일단 Runpod에 올려봄

같은 워크플로, 어디에 올릴까?

Comfy API와 Runpod Serverless에 MiniMax H3 워크플로를 올려서 재 본 준비·속도·비용

김진의

질문

ComfyUI로 만든 워크플로를 앱에서 부르려면 API가 필요합니다. 두 갈래 중 어디가 나을까요?

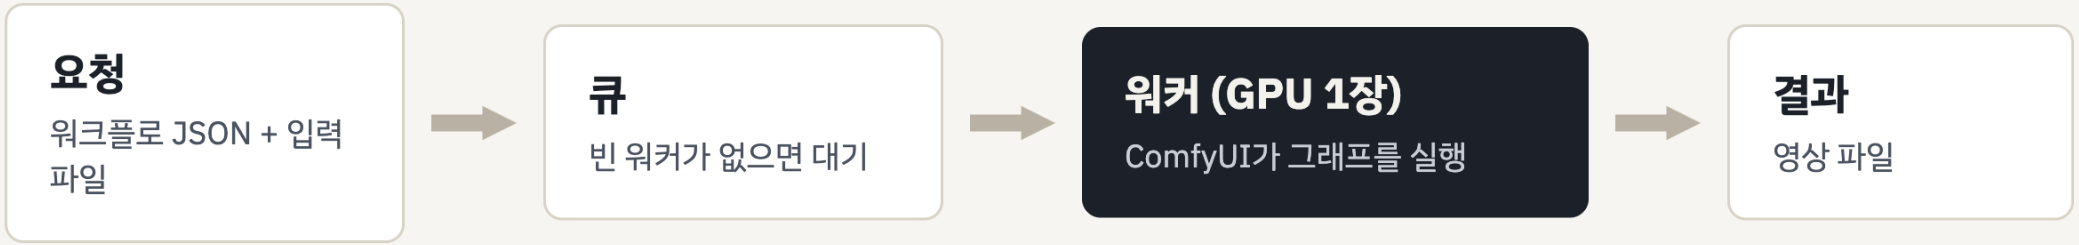
Comfy API

Comfy Org의 관리형 배포, 2026-09-30 출시. 환경 관리를 맡긴다.

Runpod Serverless 직접 구축

이미지·모델·핸들러를 직접 만든다. GPU와 형식을 쥔다.

배경: 서버리스 GPU API는 이렇게 돈다



min · max

항상 켜 둘 워커 수와 최대 워커 수. min 0이면 안 쓸 때 GPU 비용 0.

idle

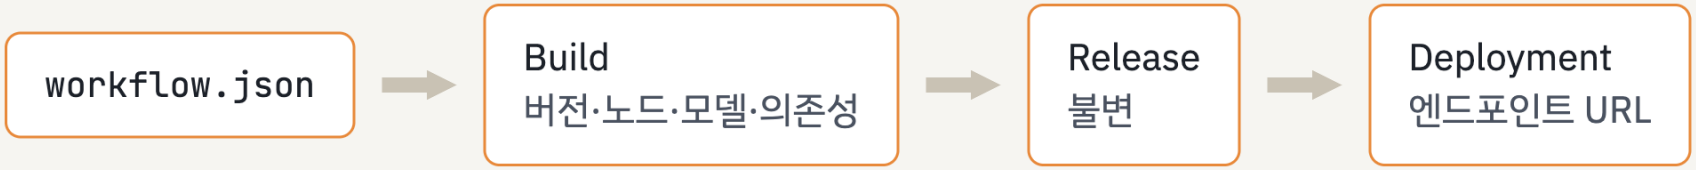
일이 끝난 워커가 내려가기 전까지 기다리는 시간. 이 시간도 과금.

cold · warm

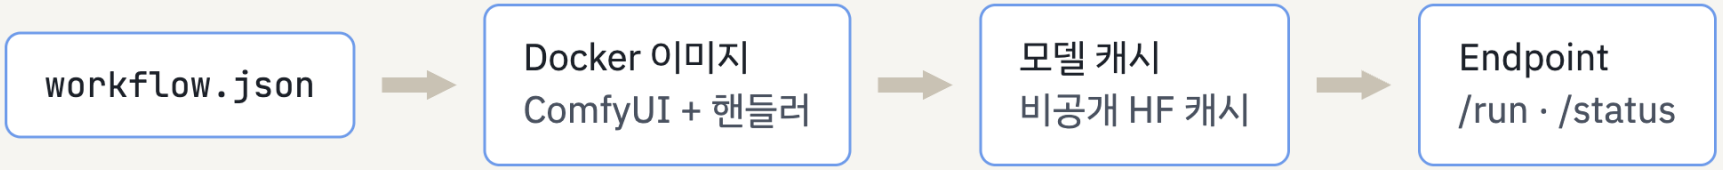
워커를 새로 띄우면 cold(기동·모델 로딩 대기), 떠 있는 워커가 받으면 warm.

두 갈래의 배포 구조

Comfy API



Runpod Serverless (직접 구축)



Runpod 쪽은 이만큼을 직접 준비했습니다

01

이미지

torch 2.9.1 베이스에 ComfyUI 커밋 고정, CPU 기동 검사

02

핸들러

입력 영상 정규화(ffmpeg), 그래프 생성, base64 입출력

03

모델 42GB

이미지에 넣지 않고 비공개 HF 저장소 + Runpod 모델 캐시

04

엔드포인트

Server Edition GPU만, CUDA ≥ 13.0, min 0 / max 1, idle 5초, FlashBoot

05

첫 요청 검증

결과 회수, 워커 0으로 내려가는지 확인

모델 캐시 전 첫 요청 대기

336초



캐시 적용 후 대기

31초

워커 기동 로그: 모델 확인 12.3초, ComfyUI 준비까지 18.3초

2026-10-17 엔드포인트 구축 기록 · 대기 = Runpod delayTime, 각 1회 관측

같은 그래프, 같은 GPU, 같은 시드로 맞춘 조건

조건	Comfy API	Runpod Serverless
워크플로	MiniMax H3 Ref2VA + Turbo4 LoRA	같은 18노드 그래프
GPU	RTX PRO 6000 96GB × 1	RTX PRO 6000 96GB × 1
워커	min 0 / max 1, 유휴 30초	min 0 / max 1, 유휴 5초
모델 (약 42GB)	Comfy network storage	비공개 HF 캐시
출력	1344×768 · 124프레임 · 5.17초	같음
측정	cold 3회 + warm 5회	cold 3회 + warm 5회

2026-10-19 21:07–22:13 KST · 같은 Mac에서 제출~완료 확인까지 측정 · ComfyUI 커밋 5cc4b870 양쪽 동일

Comfy API 준비에서 손이 간 곳

```
$ comfy build init --from-workflow h3.api.json
custom nodes: 0 · models: 0
4 models … need a sourceUri
video_vae … (maybe fl2va_pruned…)

$ comfy build refs resolve <5 files>
→ Comfy-Org/MiniMax-H3 (5/5 공식 저장소)

$ comfy build release create --watch
$ comfy deploy up --min 0 --max 1
```

첫 스펙의 모델은 0개

출처(sourceUri)는 직접 채워야 했습니다. VAE 후보로는 엉뚱한 확산 모델을 추천했습니다.

이름만 같은 후보

영상 VAE 후보에 크기가 다른 파일이 섞여 나와 공식 저장소 것을 직접 골랐습니다.

Release 6분 35초 · 배포 약 4분 25초

39GB 모델 스테이징 약 3분 포함

같은 시드, 사실상 같은 결과

Runpod

Comfy API



시드 42113 · 12·62·112번째 프레임 · 16개 결과 모두 1344×768, 24fps, 124프레임

warm 5회 · 클라이언트 기준 중앙값

196s 165s

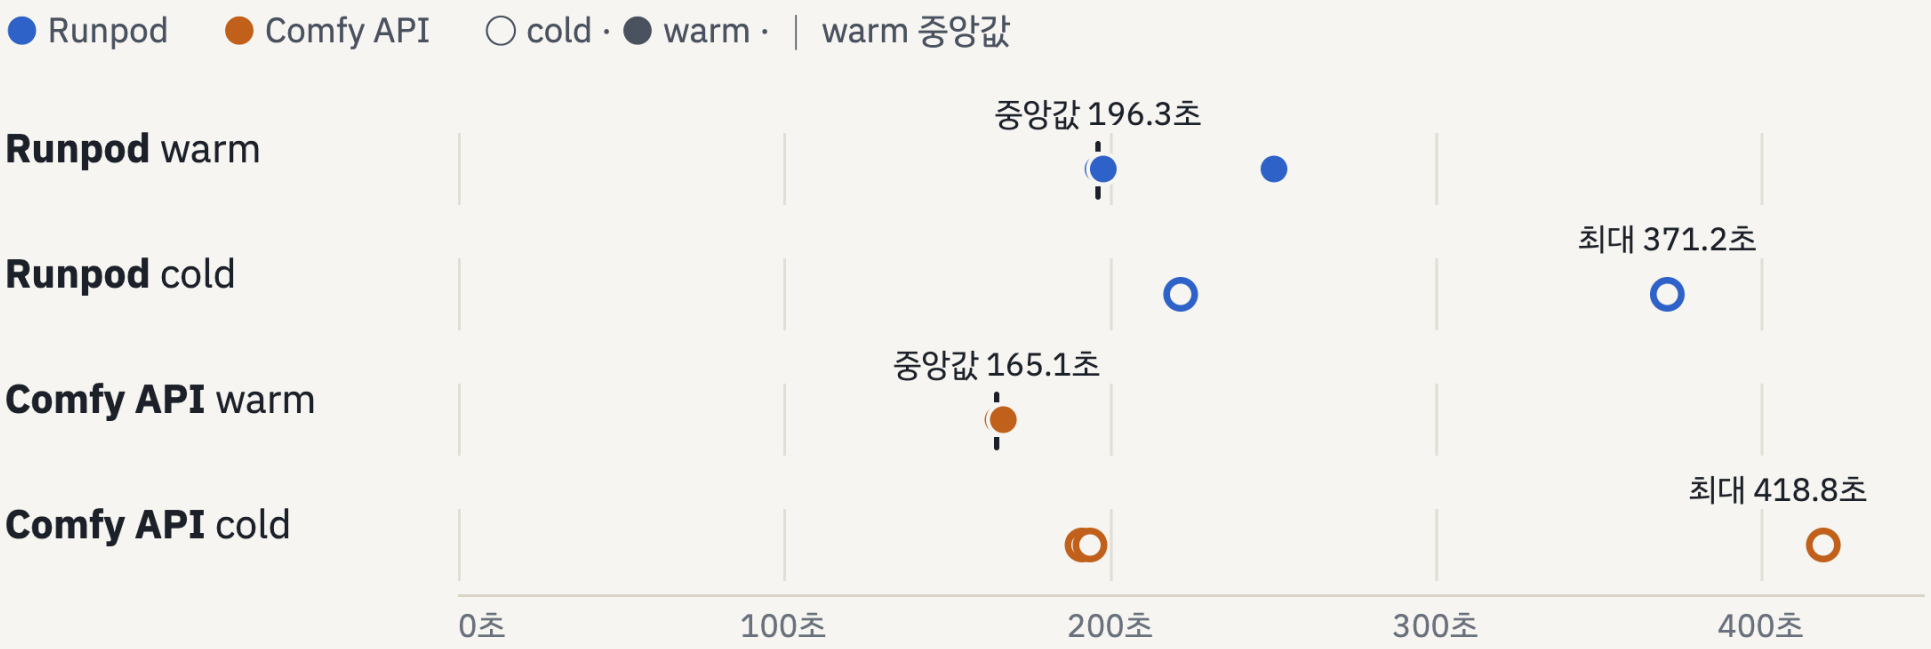
Runpod Serverless

Comfy API

다섯 번 모두 1초 안쪽으로 고르게, 매번 약 30초 차이

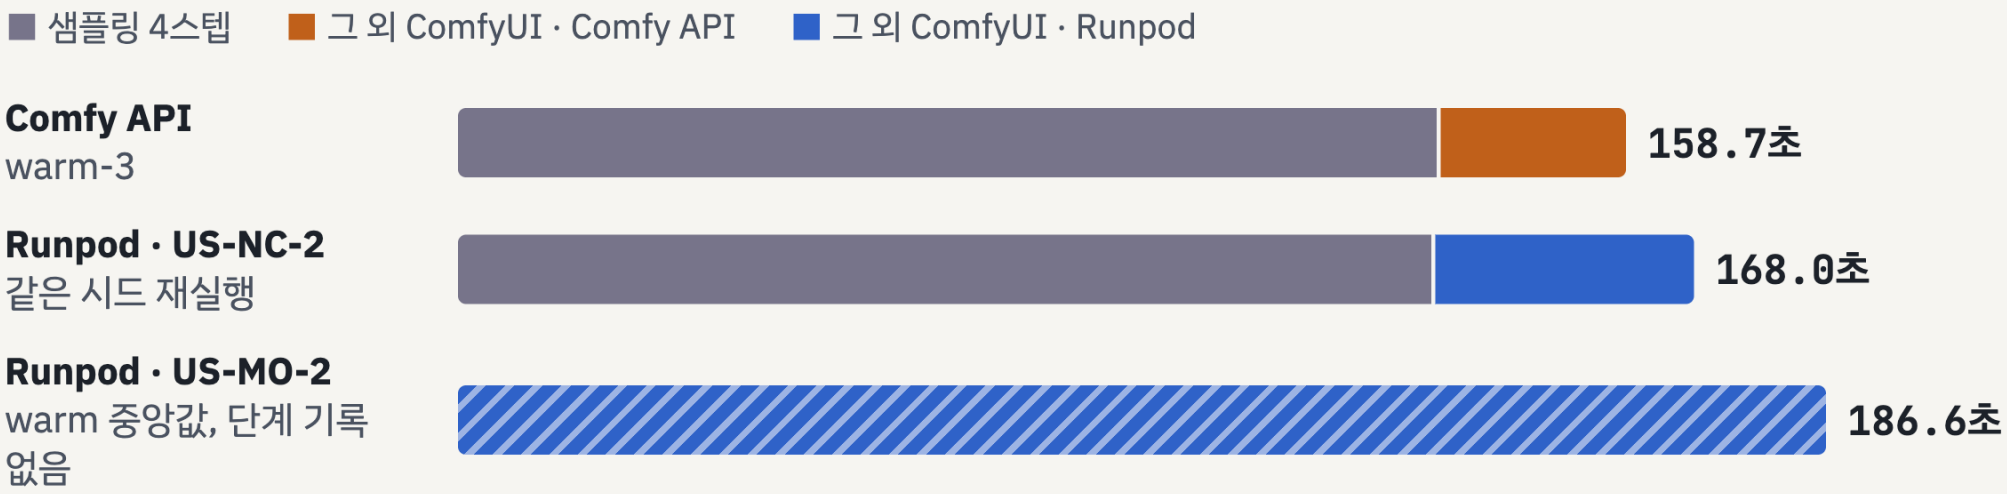
Runpod 196.3초 (195.7–250.5) · Comfy API 165.1초 (164.6–167.4) · 플랫폼 실행 시간 189.0초 vs 161.3초

요청 16번: warm은 고르고, cold는 흔들렸다



클라이언트 기준 제출~완료 시간 · Runpod warm 195.7–250.5초, cold 221.8 / 221.9 / 371.2초 · Comfy API warm 164.6–167.4초, cold 191.3 / 193.9 / 418.8초

샘플링은 같았고, 30초는 그 밖에서 났다



샘플링 차이 0초

133.4 vs 132.7초, 스텝당 약 33초

약 9초: torch 버전 (추정)

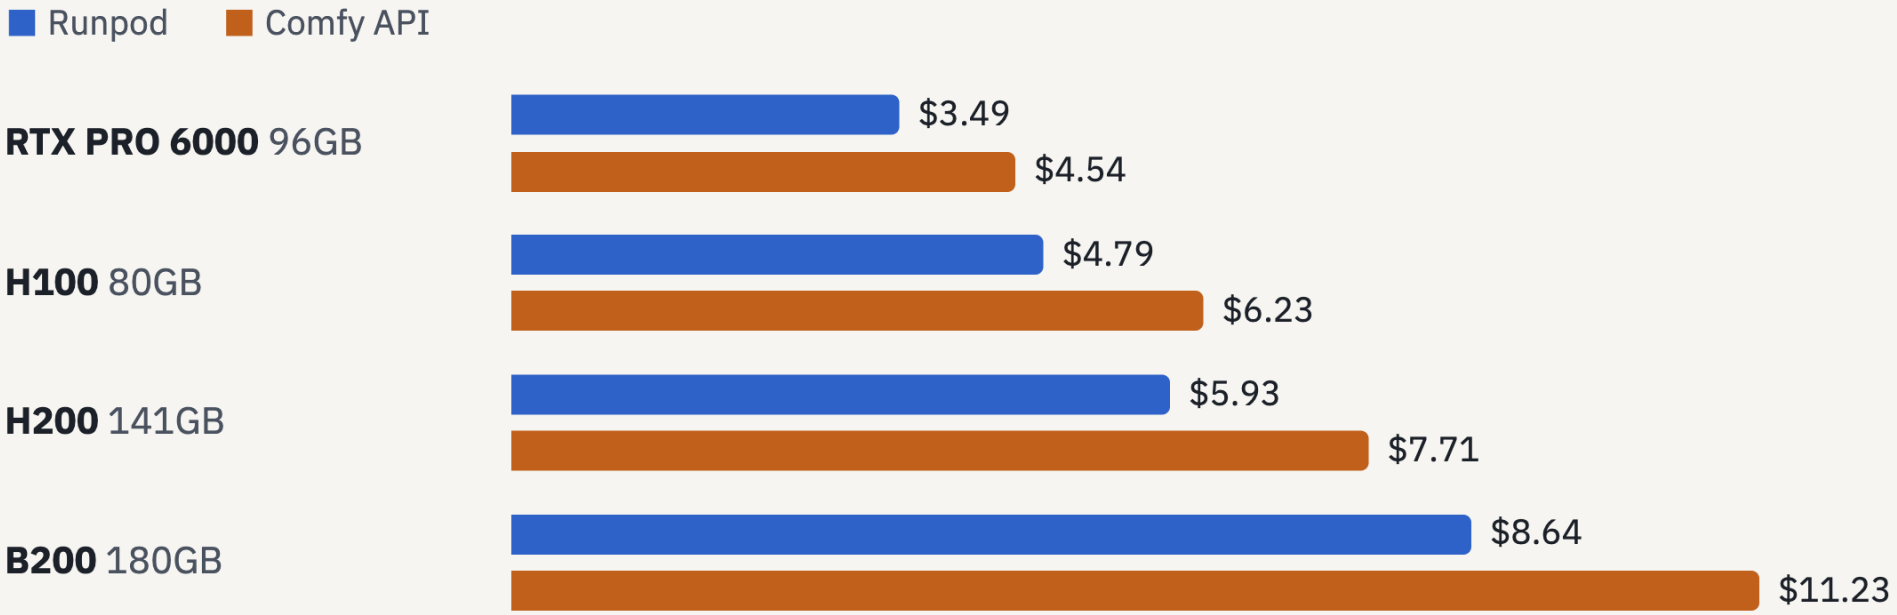
2.9.1에서 conv3d 우회가 켜짐 · 2.12.1은 없음

약 19초: GPU 서버 차이

같은 이미지·시드, 워커만 바뀜

ComfyUI 로그 Prompt executed 기준 · 막대 길이는 0~200초 · 핸들러 후처리(base64, 비교본 MP4)는 약 2초 · torch 업그레이드 재측정은 안 함

같은 GPU 단가, 네 종류 모두 정확히 1.3배



Comfy API에서 고를 수 있는 가장 작은 GPU는 96GB. 저장 공간은 $0.20 vs $0.07/GB·월.

Serverless 워커 시간당 단가, 2026-10-19 각 사 가격표 · 막대 길이는 $0~$12 · Comfy API는 Standard($20/월) 이상 플랜 필요

그런데 요청 한 건으로 보면 차이가 줄어든다



단가는 30% 비쌌지만 생성이 15% 빨라서, warm 1건 기준 차이는 **약 11%**.

계산값: 189초 × $3.49/h, 161초 × $4.54/h · 실제 청구에는 cold 기동·유휴·저장 공간 포함, 2026-10-20 조회 · 막대 길이는 $0~$0.30 · Comfy 구독료 별도

맡길 것과 쥘 것으로 고르기

Comfy API부터

- 노드·모델·의존성 관리가 제일 손이 많이 갈 때
- 테스트한 환경 그대로 배포(불변 Release)가 중요할 때
- 96GB급 GPU가 어차피 필요한 무거운 워크플로

Runpod 직접 구축

- 24~48GB GPU로 충분한 가벼운 워크플로
- 요청·응답 형식을 바꿔야 할 때 (S3 업로드 등)
- ComfyUI 말고 다른 작업도 같이 돌릴 때

이번처럼 96GB가 필요하면 요청당 차이는 11% 안팎. **이미지·torch를 직접 최신으로 유지할 시간이 있는지**가 기준입니다.

측정하면서 걸린 함정

겪은 일	그래서 이렇게 했다
Comfy 상태는 제출 2초 뒤부터 running	실제 시작은 5분 25초 뒤 · started_at 타임스탬프로 계산
문서의 metrics.queue_ms가 응답에 없음	created·started·completed로 직접 나눔
Comfy 출력에 입력 영상도 섞여 옴	SaveVideo 노드(17)만 저장
워커 상태 스냅샷이 약 5분마다 갱신	마지막 작업 30초 뒤에 찍힌 스냅샷만 '0'으로 인정
warm 순서를 양쪽 cold 뒤에 두면 Runpod이 식음	각 cold 바로 뒤에 같은 쪽 warm 5회
배포만 멈추면 저장 공간 과금 계속	Deployment와 Build 모두 삭제 후 목록 재확인

정리

생성은 같았고, 차이는 이미지 버전과 GPU 서버에서 났습니다.

단가 1.3배는 무거운 워크플로에서 요청당 11%로 줄었습니다.

cold는 양쪽 모두 3~7분, 운에 달렸습니다.

자세한 글: Runpod Korea User Group · Oh My GPU [게시 후 링크]
측정 스크립트·결과: github.com/wlsdml1114/omg-runpod-media · recipes/video/06

Q&A