RunPod 스터디, 2026년 11월

8비트 → 4비트, 손해일까?

Qwen3.5와 Gemma 4를 RunPod에 띄워 직접 재 봤습니다

배경

“4bit는 항상 손해”라고 생각했다

생각

4bit로 줄이면 성능이 크게 떨어진다

주변에서도 그렇게 들음

그런데

써 본 GLM은 4bit인데도 괜찮았다

직접 써 본 큰 모델

그래서

몇 B부터 4bit가 괜찮은지 직접 재 보자

모델 크기별로 비교

질문

확인하고 싶었던 4가지

Q1

8bit는 원본과 같을까?

Q2

4bit는 몇 B부터 괜찮을까?

Q3

메모리가 같다면,
작은 원본 vs 큰 4bit?

Q4

4bit는 정말
빠르고 쌀까?

양자화란

숫자를 더 적은 비트로 담는 것

원본 16bit



8bit (FP8)



4bit (AWQ)



메모리 ↓

속도 ↑

정확도는?

FP8: 가중치와 계산을 모두 8bit로

AWQ: 가중치만 4bit로, 중요한 값은 덜 줄임

용어

알고 보면 편한 용어 4개

PTQ vs QAT

PTQ: 학습이 끝난 뒤 줄임 (AWQ, GPTQ)
QAT: 4bit가 될 걸 알고 학습 (Gemma 공식판)

Dense vs MoE

Dense: 모든 파라미터가 매번 계산
MoE: 전문가 일부만 계산 (35B 중 3B만 사용)

'떨어짐'은 어떻게 판정?

같은 문제를 8bit, 4bit가 각각 풀고
우연으로 보기 어려운 하락만 '떨어짐'

찍기 수준

4지선다는 아무렇게나 골라도 25%
그 근처 점수는 비교해도 의미가 적음

[실험 1] 방법

같은 문제를 정밀도만 바꿔서 풀게 했다

모델

Qwen3.5

2B, 4B, 9B, 27B

같은 계열에서 크기만 다른 4개

정밀도

3가지

원본, 8bit, 4bit

vLLM으로 같은 설정에서 실행

문제

약 2,400개

수학 + 한국어 지식

모든 모델이 같은 문제를 풂

같은 문항끼리 정답을 짝지어 비교

조합마다 RunPod Pod 1개, 끝나면 삭제

[실험 1] Q1. 8bit는 원본과 같을까?

8bit는 원본과 같았다

1점 이내

원본 vs 8bit 점수 차이

2B, 4B, 9B 모두 (100점 만점)

40% 절약

원본 대비 메모리

9B: 17GB → 10GB

어떻게 확인했나

방법

2B, 4B, 9B를 원본과 8bit로 각각 띄움

비교

같은 문제 2,354개의 정답을 문항별로 비교

결과

수학, 한국어 모두 우연 수준의 차이

[실험 1] Q2. 4bit는 몇 B부터 괜찮을까? (4bit: AWQ)

쉬운 문제에선 9B부터 4bit도 손해 없음

모델	수학 (쉬움)	한국어 지식
2B	73.2 → 71.7 차이 없음	36.0 → 31.5 4.5점 떨어짐
4B	92.3 → 92.8 차이 없음	51.1 → 46.7 4.4점 떨어짐
9B	93.5 → 93.8 차이 없음	56.7 → 56.0 차이 없음
27B	97.0 → 96.8 차이 없음	67.8 → 68.2 차이 없음

왼쪽 8bit, 오른쪽 4bit 정답률(%). 같은 문제끼리 비교해서 우연으로 보기 어려운 하락만 '떨어짐'

[실험 1] Q3. 메모리가 같다면?

작은 모델 원본보다 큰 모델 4bit

메모리 약 18GB

9B 원본

한국어 지식 **57점**

vs

메모리 약 19GB

27B 4bit

한국어 지식 **68점**

어떻게 확인했나

측정

vLLM 로그로 실제 사용 메모리 확인

비교

메모리가 비슷한 작은 원본과 큰 4bit 3쌍

결과

3쌍 모두 큰 모델 4bit가 더 잘 맞힘

[실험 1] Q4. 4bit는 정말 빠르고 쌀까?

4bit가 더 빠르고 더 쌌다

1.6배

8bit보다 빠른 답변

혼자 쓸 때 기준, 9B와 27B 모두

35% 절약

8bit 대비 100만 토큰 비용

27B, L40S 기준 $0.54에서 $0.35로

GPU 선택

9B: 4090이 L40S보다 빠름

27B: 4090에 안 들어감

어떻게 확인했나

방법

9B, 27B를 GPU 두 종류에 띄움

측정

답변 길이 고정, 동시 요청 1~48개

계산

GPU 시간당 요금을 처리량으로 나눔

[실험 1] 정리 (쉬운 문제 기준)

4bit는 “개손해”가 아니었다

8bit	고민 없이 써도 된다
4bit	9B 이상이면 OK, 작은 모델은 지식 과제 주의
메모리가 빠듯하면	작은 원본 대신 큰 4bit

실험 1을 마치고 든 의문

문제가 쉬워서 차이가 없었던 건 아닐까?

문제가 쉬움

**4B 이상은 수학 90점 넘음
떨어질 여지가 없음**

초등 수준 문장제(GSM8K)

유형이 좁음

**수학과 상식뿐
금융은 없음**

실제 서비스 분야와 거리

한 번만 측정

**우연한 차이인지
확인하기 어려움**

다시 풀면 얼마나 달라지는지 모름

그래서 실험 2는 더 어렵고 넓은 문제로, 3번씩 다시 쟀습니다. Gemma 4와 MoE 모델도 넣었습니다

[실험 2] 방법

더 어렵게, 더 넓게, 3번씩

문제 1,913개

어려운 수학 400

한국어로 옮긴 MATH 최고 난도

어려운 한국어 지식 585

KMMLU-HARD, 큰 모델도 틀린 문제만

금융 928

회계, 세무, 경제, 경영, 부동산 등

모델 20개 조합

Qwen3.5 dense

2B, 4B, 9B, 27B

Gemma 4 dense

E2B, E4B, 12B, 31B

MoE

Qwen3.5-35B-A3B

Gemma 4-26B-A4B

측정 방법

각 모델을 **8bit, 4bit**로

Pod 하나 켜서 **3번 반복**

문제마다 3번 평균을 내서 **짝 비교**

[실험 2] 문제 예시

이 정도 난이도의 문제들

어려운 수학

양의 정수 x, y가
$2x^2y^3 + 4y^3 = 149 + 3x^2$ 를
만족할 때, x + y는?

정답: 5

어려운 한국어 지식 (세무)

관세 환급 규정의 세부 내용을 묻는 문제

4지선다, 법 조문을 자세히 알아야 풂

금융

절약의 역설 개념을 묻는 문제

경제, 금융 실무 지식

[실험 2] Qwen3.5 결과 (4bit: AWQ)

어려운 문제에선 27B도 수학이 떨어졌다

모델	어려운 수학	금융
2B	17.8 → 13.6 **4.2점 떨어짐**	40.0 → 36.3 **3.7점 떨어짐**
4B	52.2 → 50.8 차이 없음	50.4 → 47.7 **2.7점 떨어짐**
9B	60.0 → 57.8 차이 없음	55.5 → 54.2 차이 없음
27B	88.9 → 86.4 **2.5점 떨어짐**	65.6 → 66.3 차이 없음

왼쪽 8bit, 오른쪽 4bit 정답률(%). 같은 문제끼리 비교해서 우연으로 보기 어려운 하락만 '떨어짐'. 3번 푼 평균

[실험 2] Gemma 4 결과 (4bit: Google 공식판)

Gemma도 31B가 되어서야 차이가 없었다

모델	어려운 수학	금융
E2B	48.4 → 42.3 6.1점 떨어짐	45.9 → 43.9 차이 없음
E4B	63.2 → 62.4 차이 없음	49.0 → 50.4 차이 없음
12B	79.8 → 76.3 3.5점 떨어짐	61.9 → 59.9 차이 없음
31B	92.6 → 92.7 차이 없음	74.2 → 72.8 차이 없음

왼쪽 8bit, 오른쪽 4bit 정답률(%). 같은 문제끼리 비교해서 우연으로 보기 어려운 하락만 '떨어짐'. 3번 푼 평균이고, E2B와 E4B는 2B, 4B급 크기

[실험 2] MoE 결과

MoE 두 모델은 결과가 정반대였다

모델	어려운 수학	한국어 지식	금융
Qwen 35B 4bit: Qwen 공식판	73.6 → 72.8 차이 없음	42.3 → 41.6 차이 없음	62.0 → 60.9 차이 없음
Gemma 26B 4bit: 커뮤니티판	83.2 → 77.5 5.7점 떨어짐	45.6 → 40.5 5.1점 떨어짐	68.2 → 66.2 2점 떨어짐

왼쪽 8bit, 오른쪽 4bit 정답률(%). 같은 문제끼리 비교해서 우연으로 보기 어려운 하락만 '떨어짐'. 3번 푼 평균

실험 2를 마치고 든 의문

같은 4bit라도 방식을 바꾸면 달라질까?

지금까지 쓴 4bit (AWQ, GPTQ)

4bit 정수로 저장,
계산할 땐 16bit로 풀어서

메모리는 줄지만 계산은 그대로
Gemma MoE에서는 5점씩 떨어짐

NVFP4 (NVIDIA)

4bit 실수 그대로 계산,
16개 숫자마다 눈금 따로

계산도 4bit로
4bit로 바로 계산하는 건 Blackwell GPU부터

그래서 실험 3

모델
실험 2에서 떨어졌던 Gemma 26B MoE

GPU
RTX PRO 4500 Blackwell

측정
실험 2와 같은 문제 3번, 속도도 같이

[실험 3] Gemma 26B MoE, 4bit 방식만 바꿔서

NVFP4로 바꾸니 8bit와 같아졌다

모델	어려운 수학	한국어 지식	금융
AWQ 커뮤니티판, 실험 2	83.2 → 77.5 **5.7점 떨어짐**	45.6 → 40.5 **5.1점 떨어짐**	68.2 → 66.2 **2점 떨어짐**
NVFP4 NVIDIA 공식판, 실험 3	83.2 → 83.2 **차이 없음**	45.6 → 44.8 **차이 없음**	68.2 → 67.5 **차이 없음**

왼쪽 8bit, 오른쪽 4bit 정답률(%). 같은 문제끼리 비교해서 우연으로 보기 어려운 하락만 '떨어짐'. 8bit 점수는 실험 2에서 L40S로 잰 값이고, NVFP4만 Blackwell에서 잼

[실험 3] 속도, 같은 Blackwell GPU에서 AWQ와 비교

48개가 몰리면 NVFP4가 더 처리했다

혼자 쓸 때 (요청 1개)

AWQ **154** tok/s
NVFP4 **114** tok/s

AWQ가 더 빠름

요청이 몰릴 때 (48개 동시)

AWQ **1,890** tok/s
NVFP4 **2,155** tok/s

NVFP4가 14% 더 많이

100만 토큰 비용 (48개 동시)

AWQ **$0.106**
NVFP4 **$0.093**

속도를 잰 조합 중 최저

tok/s는 1초에 만들어 내는 토큰 수. 혼자 쓸 때는 한 사람이 받는 속도, 몰릴 때는 GPU 전체가 처리한 양입니다. 16개 동시에서는 거의 같았고, 처음 뜰 때까지 NVFP4 약 10분, AWQ 약 7분. 조건별로 1번씩 잰 값입니다

정리

4bit는 크기와 만든 방식을 보고 고른다

Q1. 8bit는 원본과 같을까?	같다. 점수 차이 1점 이내, 메모리는 40% 덜 씀
Q2. 4bit는 몇 B부터 괜찮을까?	쉬운 문제는 9B부터, 어려운 문제는 30B급부터 (모델 수가 적어 더 확인 필요)
Q3. 같은 메모리라면?	작은 원본보다 큰 모델 4bit가 낫다
Q4. 4bit는 빠르고 쌀까?	8bit보다 1.6배 빠르고, 비용은 최대 35% 싸다
새로 알게 된 것	크기가 전부는 아니다. 4bit를 만든 방식도 결과를 바꿨다

공식판도 작은 모델은 떨어졌습니다. 어떤 4bit든 쓰려는 문제로 먼저 재 보는 게 안전합니다

사용한 RunPod 기능

필요할 때 빌리고, 끝나면 바로 반납

GPU Pod

켠 시간만큼 과금
시간당 L40S $1.09, 4090 $0.89
RTX PRO 4500 Blackwell $0.72

Secure Cloud

데이터센터 서버라 안정적
대신 재고가 없을 때가 있음

Docker 이미지

vLLM 공식 이미지에
모델 이름만 바꿔 실행

Pod 접속 주소

포트마다 주소가 생김
모델 호출, 로그 보기

API

Pod 만들고 지우기를 코드로
Pod별 요금 확인

GPU 재고 조회

남은 GPU를 먼저 조회
없으면 비슷한 GPU로

다음엔 Network Volume에 모델을 받아 두려고 합니다. Pod가 뜨기까지 길게는 19분 걸렸습니다

사용 크레딧

세 번 실험하는 데 $15



실험 1 약 $6.0 (그중 시행착오 $3.3) **실험 2 약 $8.6** (20개 조합을 3번씩) **실험 3 약 $0.3** (Blackwell)

실험 1 이후 바꾼 것

- Pod 하나 켜서 3번 연달아 실행
- 끝나면 바로 삭제
- 예산을 넘을 조합은 시작 전에 중단

다음엔

- 모델은 Network Volume에 받아 두기
- 어려운 수학은 큰 모델에서 오래 걸림
- GPU 이름은 미리 확인

다음 실험 방향

이번에 다루지 못한 것들

바로 다음 (준비 끝)

KV 캐시 양자화

대화 기억 공간을 8bit로 줄여 긴 문서와 동시 처리를 늘릴 수 있을까?

추천

한국어 보정 4bit

커뮤니티 AWQ 손실을 한국어 문장으로 다시 만들면 줄일 수 있을까?

추천

Thinking 모드

길게 생각하면 4bit 오차가 쌓일까, 만회할까?

NVFP4 더 넓게

dense 모델과 다른 계열에도 써 보기

3bit, 2bit

큰 모델은 어디까지 버틸까?

추측 디코딩

작은 모델이 먼저 쓰고 큰 모델이 검사
답은 같고 더 빠르다고 함