GPU 한 장으로
동시 요청을 얼마나 처리할 수 있을까?

RTX 5090에서 한국어 LLM 서빙의 한계와 병목 측정

1차 실험 · Kanana 1.5 8B · vLLM · RunPod · 2026년 11월

목적과 핵심 질문

GPU 한 장의 서빙 한계와 구간별 소요 시간 파악

질문 1. 동시 요청 수를 늘려도 GPU가 처리하는 양이 거의 늘지 않는 지점은 어디인가?

서버가 동시에 처리하는 요청 수를 1~256으로 늘려 측정했다.

질문 2. 답변이 눈에 띄게 느려지기 시작하는 동시 요청 수는 몇인가?

답변이 끝날 때까지 걸린 시간(latency)을 동시 요청 수별로 비교했다.

질문 3. 답변 하나를 만드는 동안 어느 단계가 가장 오래 걸리고, 동시 요청이 늘면 어느 단계가 느려지는가?

대기열(queue), 입력 처리(prefill), 답변 생성(decode)으로 나눠 확인했다.

실험 설계

동시 요청 수만 변경, 나머지 조건 고정

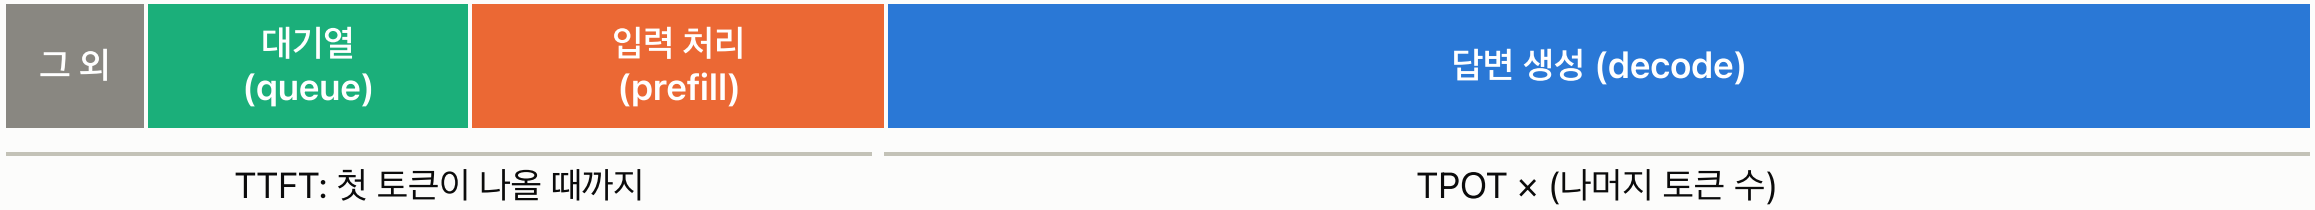
GPU	RTX 5090 1장 (32GB)
플랫폼	RunPod, 시간당 GPU $1.19
모델	Kanana 1.5 8B Instruct 2505 (BF16)
서빙	vLLM 0.26.0, 기본 설정
데이터	한국어 ShareGPT 6,014건

도구	vllm bench serve, 채팅 API
요청 방식	지정한 동시 수를 항상 유지
동시 요청	1, 2, 4 … 128, 256 (9단계)
반복	단계별 3회, 총 27회

vLLM 기본 설정을 썼고, 토큰 선택 기능(FlashInfer 샘플러)만 기본값과 다르게 설정했다.

무엇을 쟀나

답변 완료까지의 단계별 소요 시간 측정



- **TTFT** 첫 토큰이 나올 때까지
- **TPOT** 토큰 하나를 만드는 시간
- **latency** 답변이 끝날 때까지 걸린 시간
- **throughput** GPU가 1초에 처리하는 양

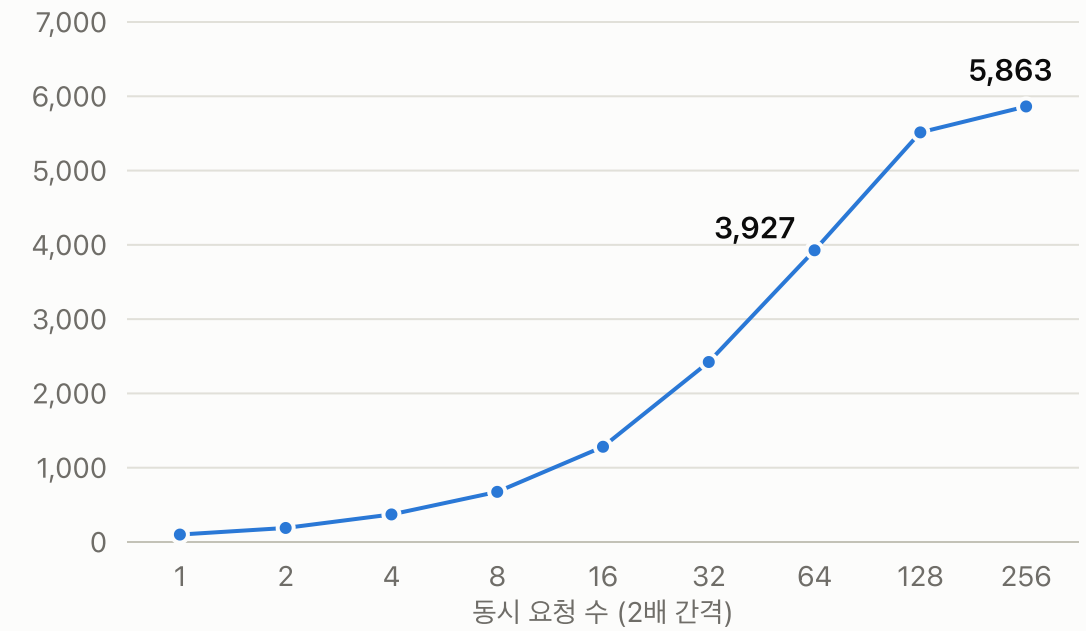
사용자가 느끼는 속도와 그 원인이 되는 단계를 함께 봤다. 그림의 단계 폭은 설명용이다.

결과 1

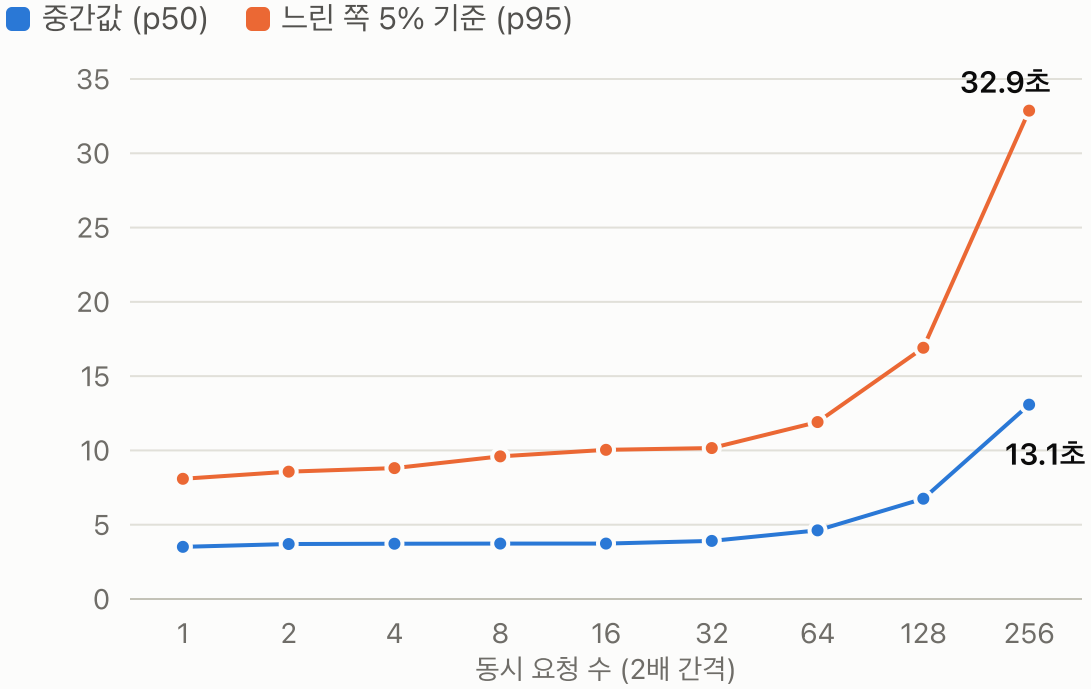
동시 요청 128~256 사이에서 처리량 증가 정체, 답변 시간 증가

GPU가 1초에 생성한 토큰 수

3회 평균



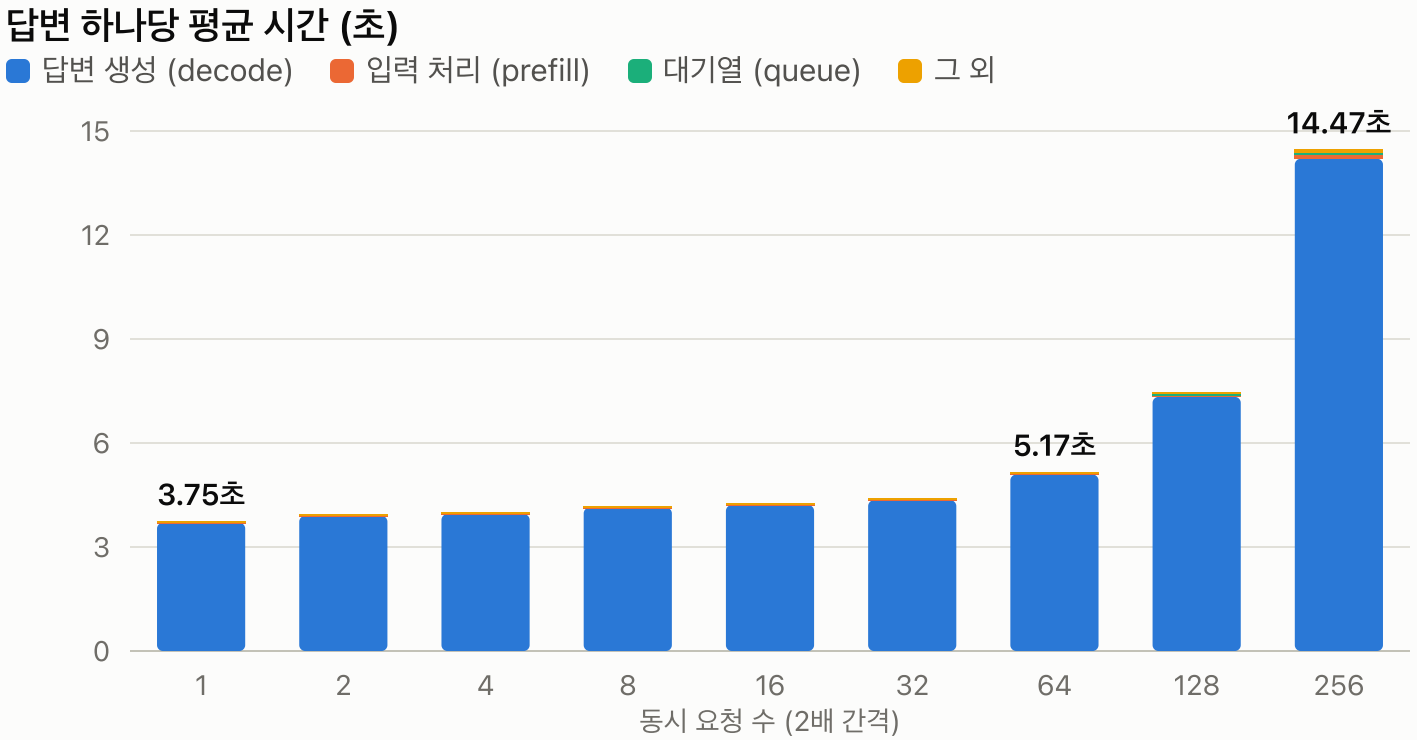
답변이 끝날 때까지 걸린 시간 (latency, 초)



64까지는 답변 시간이 거의 그대로다(중간값 3.5초 → 4.6초). 128 → 256은 처리량 +7%, 답변 시간은 약 2배다.

결과 2

전체 시간의 약 98%가 답변 생성(decode) 단계



동시	메모리(KV) 사용률	토큰당 시간
64	23.6%	15.1ms
128	45.0%	21.7ms
256	**88.9%**	**42.3ms**

대기열과 입력 처리는 최대 0.07초, 0.11초다. 서버가 여러 요청을 한 묶음으로 처리해 **요청마다 GPU를 나눠 쓰느라** 답변 생성이 느려진다.

느려지는 원인은 GPU 연산이고, 동시 256에서는 메모리(KV 캐시)도 최대 99.9%까지 찼다.

결론

RTX 5090 한 장, 동시 64건까지 체감 유지

동시 요청	관찰
64까지	**답변 시간 중간값 약 4.6초, 체감 거의 유지**
128	중간값 약 6.8초, 느린 쪽 5% 기준 약 16.9초
256	실패 없음, 중간값 약 13.1초, 느린 쪽 약 32.9초

- 질문 1: 동시 128~256 사이, 초당 약 17건에서 처리량이 거의 늘지 않았다.
- 질문 2: 답변 시간 중간값은 64까지 3.5초 → 4.6초, 128에서 6.8초, 256에서 13.1초였다.
- 질문 3: 답변 생성(decode)이 약 98%이고 3.70초 → 14.20초로 가장 많이 늘었다.

이 결과의 한계

- 동시 수를 고정해 대기열 지연이 덜 드러남
- 부하 도구가 GPU와 같은 Pod에서 실행됨
- 단일 턴, 시스템 프롬프트 없는 요청
- 측정 범위는 LLM 서버까지
- FlashInfer 샘플러를 끈 조건

GPU가 처리할 수 있는 양은 초당 약 17건(약 5,900토큰)이고, 줄여야 할 단계는 답변 생성(decode)이다.